5. Orquestración de pipelines en Databricks

5.1 Que é Databricks Workflows

Databricks Workflows é a funcionalidade da plataforma que permite definir, executar e programar secuencias de tarefas.

O seu obxectivo principal é automatizar procesos como:

- execución de notebooks
- cargas e transformacións de datos
- actualización periódica de táboas
- execución encadeada de distintas etapas dun pipeline

Nun contexto de enxeñaría de datos, Workflows actúa como a capa de **orquestración** do sistema.

Isto significa que permite indicar:

- que tarefas hai que executar
- en que orde deben facelo
- con que parámetros
- con que frecuencia

Convén distinguir desde o principio entre dous conceptos próximos, pero non idénticos:

- un **pipeline** é o proceso de datos, é dicir, o conxunto de etapas polas que pasa a información
- un **workflow** é o mecanismo de orquestración que executa e coordina esas etapas

Noutras palabras, o pipeline describe a lóxica do proceso e o workflow encárgase de poñelo en marcha de forma ordenada e repetible.

5.2 Workflow, job e task

En Databricks aparecen varios conceptos relacionados entre si.

Workflow

Un **workflow** é o conxunto global do proceso automatizado.

Representa a lóxica completa dun pipeline, incluíndo as súas tarefas e dependencias.

Job

Na interface de Databricks, un workflow adoita materializarse como un **job**.

Un job é o obxecto que se configura, se executa manualmente ou se programa para executarse de forma automática.

Task

Unha **task** é unha unidade de traballo dentro dun workflow.

Cada task pode realizar unha acción concreta, por exemplo:

- executar un notebook
- lanzar unha tarefa Python
- executar código SQL
- chamar a outro proceso

Un workflow pode ter unha única task ou varias tasks encadeadas.

5.3 Dependencias e fluxo de execución

As tarefas dun workflow poden executarse de forma independente ou depender unhas doutras.

Por exemplo:

1. unha primeira tarefa prepara os datos
2. unha segunda tarefa transforma a información
3. unha terceira tarefa garda o resultado final

Este tipo de relacións represéntase como un **DAG** (*directed acyclic graph*), é dicir, un grafo dirixido sen ciclos.

En Databricks, o DAG permite visualizar:

- a orde das tarefas
- que tarefas dependen doutras
- o estado de execución de cada parte do workflow

Este enfoque é moi útil para pipelines de datos, xa que facilita separar o proceso en etapas máis pequenas e controlables.

5.4 Creación dun workflow

Un workflow pódese crear desde a interface gráfica de Databricks, na sección **Workflows**.

De forma xeral, o proceso consiste en:

1. crear un novo job
2. darlle un nome descritivo
3. engadir unha primeira task
4. seleccionar o tipo de tarefa
5. indicar o notebook ou recurso que se vai executar
6. escoller o clúster de execución
7. engadir parámetros, se son necesarios
8. definir dependencias entre tasks, se hai máis dunha

As tarefas poden compartir o mesmo clúster ou executarse en clústeres distintos, segundo as necesidades do proceso.

En moitos casos, é recomendable empregar un **job cluster**, xa que se crea para a execución do workflow e se elimina automaticamente ao finalizar.

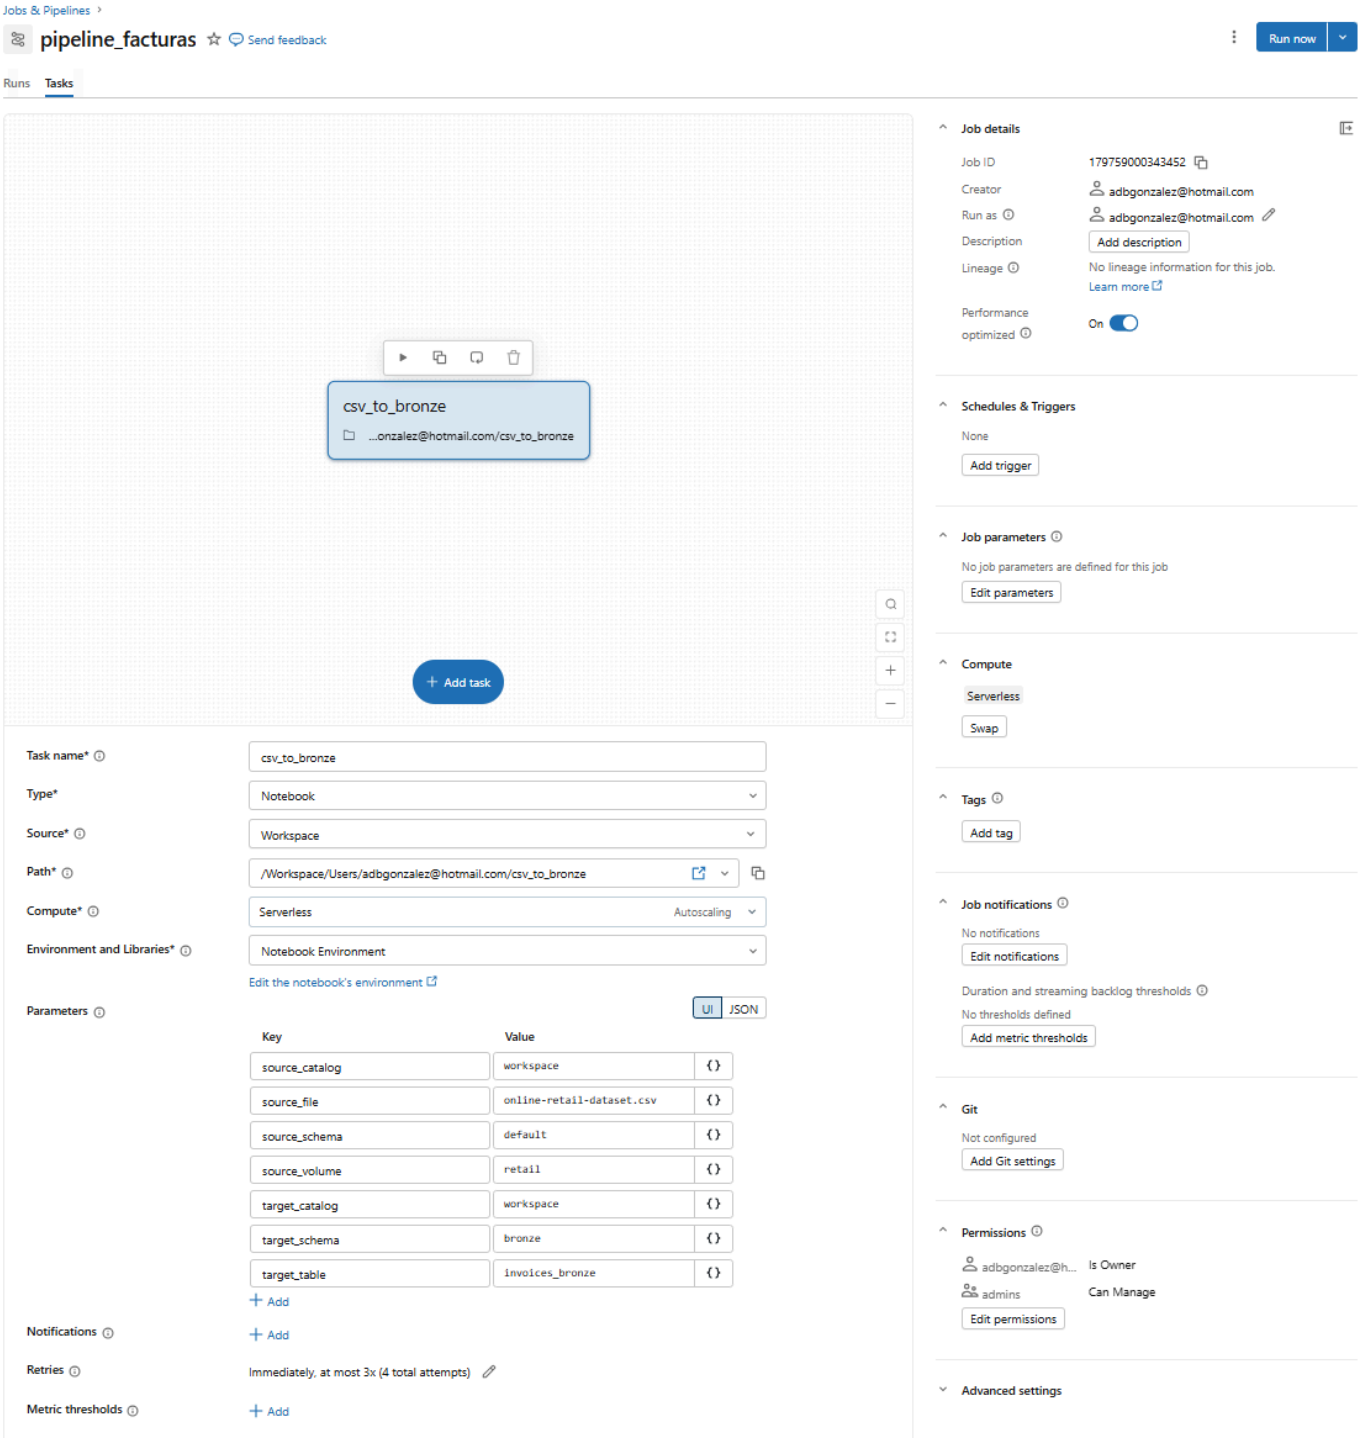

Figura 5.1. Creación dun workflow en Databricks.
Fonte: elaboración propia.

5.5 Tipos habituais de tarefas

Dentro dun workflow, Databricks permite definir distintos tipos de tarefas.

As máis habituais en proxectos de datos son:

- **Notebook**: executa un notebook de Databricks
- **Python**: executa un script ou tarefa Python

- **SQL**: executa consultas ou procesos SQL
- **Spark Submit**: lanza unha aplicación Spark máis avanzada

A opción máis natural adoita ser traballar con tarefas de tipo **Notebook**, xa que permiten integrar código, explicacións e resultados nun mesmo recurso.

5.6 Programación e disparadores

Unha das principais vantaxes de Workflows é que permite executar procesos de forma automática.

Isto pódese facer mediante diferentes mecanismos:

- execución manual
- execución periódica segundo un horario
- execución continua
- execución ao detectar a chegada dun ficheiro

Por exemplo, un pipeline pode configurarse para executarse:

- cada día
- cada hora
- cada semana
- cando aparece un novo ficheiro nunha localización vixiada

Esta capacidade converte un notebook ou unha tarefa illada nun proceso operativo e reutilizable.

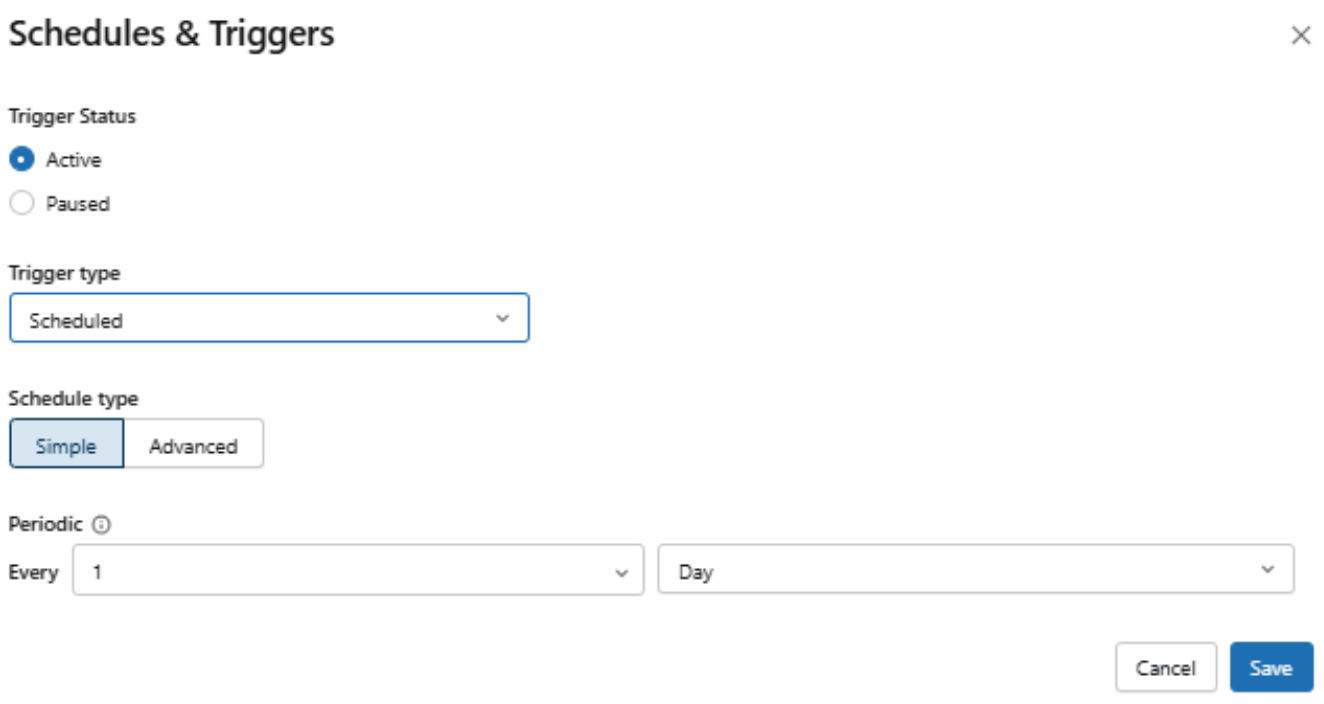

Figura 5.2. Programación dun workflow en Databricks.
Fonte: elaboración propia.

5.7 Execución e monitorización

Unha vez creado, un workflow pode executarse e supervisarse desde a propia interface de Databricks.

O sistema permite consultar:

- execucións anteriores
- duración de cada run
- estado de cada task
- erros producidos durante a execución
- ligazóns a logs e métricas

Databricks ofrece habitualmente dúas vistas principais:

- **vista de matriz**, que mostra de forma visual as execucións e o estado das tarefas
- **vista de lista**, que mostra os runs de forma tabular

Isto facilita identificar:

- tarefas correctas
- tarefas fallidas
- tarefas omitidas
- execucións máis lentas do esperado

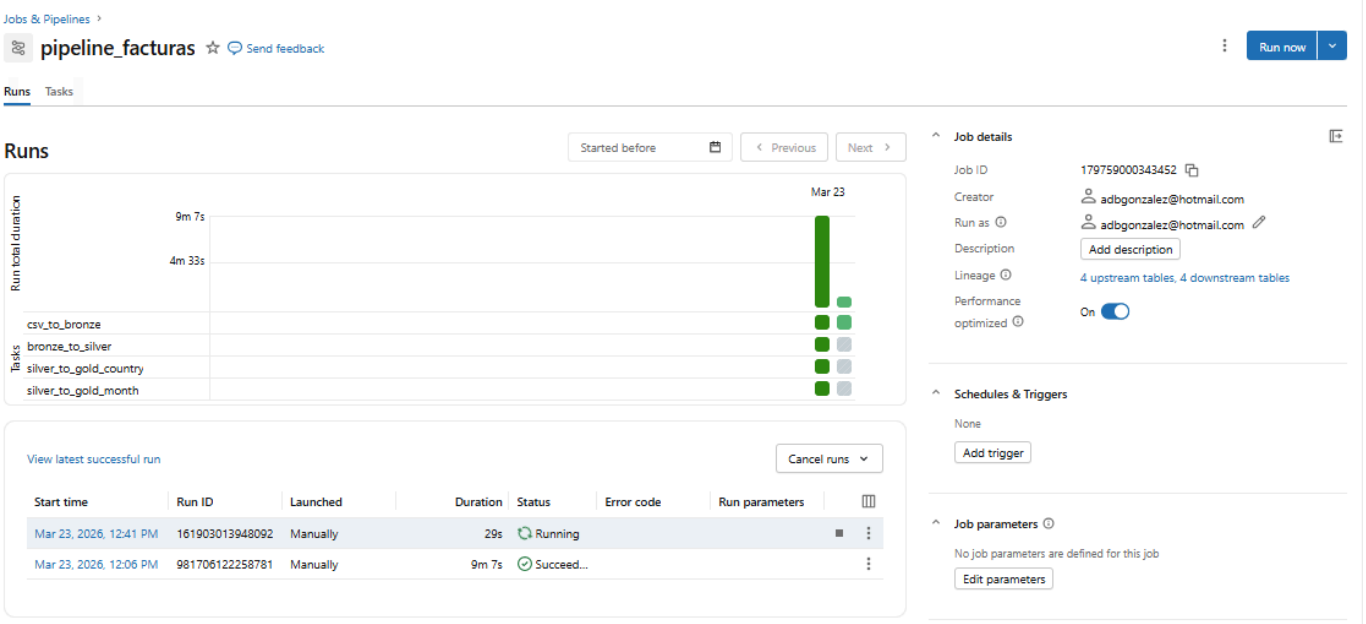

Figura 5.3. Seguimento de execucións dun workflow en Databricks.
Fonte: elaboración propia.

5.8 Parámetros en Workflows

Os workflows poden recibir **parámetros**, o que permite reutilizar a mesma lóxica con valores distintos.

Por exemplo, un mesmo notebook pode executarse cambiando:

- o catálogo
- o esquema
- a táboa de destino

- a ruta dun ficheiro
- unha data de procesamento

Esta capacidade é especialmente útil cando se queren construír pipelines máis flexibles e reutilizables.

Pódense distinguir dous niveis:

- **parámetros de task**, válidos só para unha tarefa concreta
- **parámetros de job**, compartidos por distintas tarefas do workflow

Nun exemplo sinxelo, un workflow podería lanzar un notebook de carga con parámetros como estes:

```
catalog = workspace
schema = bronze
input_file = /Volumes/workspace/default/retail/online-retail-dataset.csv
target_table = invoices_bronze
```

Estes parámetros poden ser lidos polo notebook mediante `dbutils.widgets`, tal como se viu no capítulo anterior, e empregados para construír rutas, nomes de táboas ou consultas SQL.

Por exemplo, un notebook parametrizado podería comezar así:

```
dbutils.widgets.text("catalog", "workspace")
dbutils.widgets.text("schema", "bronze")
dbutils.widgets.text("input_file", "/Volumes/workspace/default/retail/online-
retail-dataset.csv")
dbutils.widgets.text("target_table", "invoices_bronze")

catalog = dbutils.widgets.get("catalog")
schema = dbutils.widgets.get("schema")
input_file = dbutils.widgets.get("input_file")
target_table = dbutils.widgets.get("target_table")
```

Deste modo, o mesmo notebook pode reutilizarse en distintos workflows ou en distintos contextos sen cambiar o código principal.

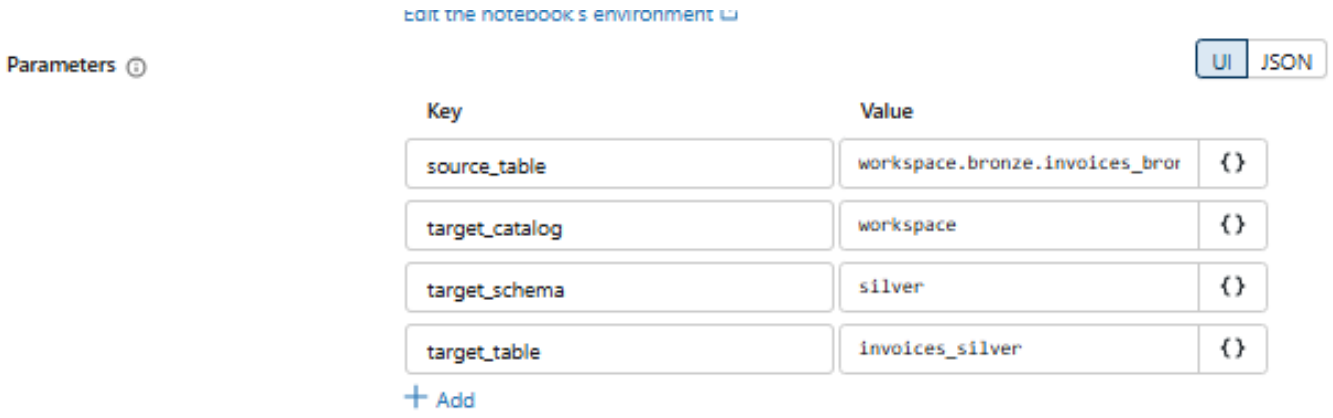

Figura 5.4. Parámetros dunha task de notebook nun workflow de Databricks.
Fonte: elaboración propia.

5.9 Parámetros e comunicación entre tarefas

Nun workflow real non abonda con executar tarefas illadas. Con frecuencia é necesario:

- pasar parámetros a unha task
- reutilizar o mesmo notebook con valores distintos
- compartir información dunha tarefa a outra

Dúas ideas especialmente útiles son:

- o uso de **widgets** para recibir parámetros nun notebook
- o uso de **task values** para compartir valores entre tarefas

Por exemplo, un notebook pode recibir parámetros como:

- catálogo
- esquema
- data de procesamento
- ruta dun ficheiro

En Databricks, isto permite construír workflows moito máis reutilizables, xa que o mesmo código pode executarse en distintos contextos sen ser reescrito.

Tamén é posible que unha tarefa deixe gardado un valor, por exemplo o nome dun volume ou a ruta dun ficheiro, para que outra tarefa o recupere máis adiante.

Este patrón é útil cando un workflow:

- crea recursos nunha primeira fase
- procesa os datos nunha segunda
- executa validacións ou limpeza nunha terceira

Un fluxo moi típico podería ser este:

1. unha primeira task recibe parámetros e prepara a ruta ou a táboa de entrada
2. unha segunda task executa a carga e garda un resultado intermedio
3. unha terceira task valida o resultado ou xera unha táboa agregada final

Nun enfoque introdutorio non é necesario entrar en todos os detalles técnicos de `task values`, pero si convén entender a idea xeral: un workflow non só executa tarefas en cadea, senón que tamén pode transmitir contexto entre elas.

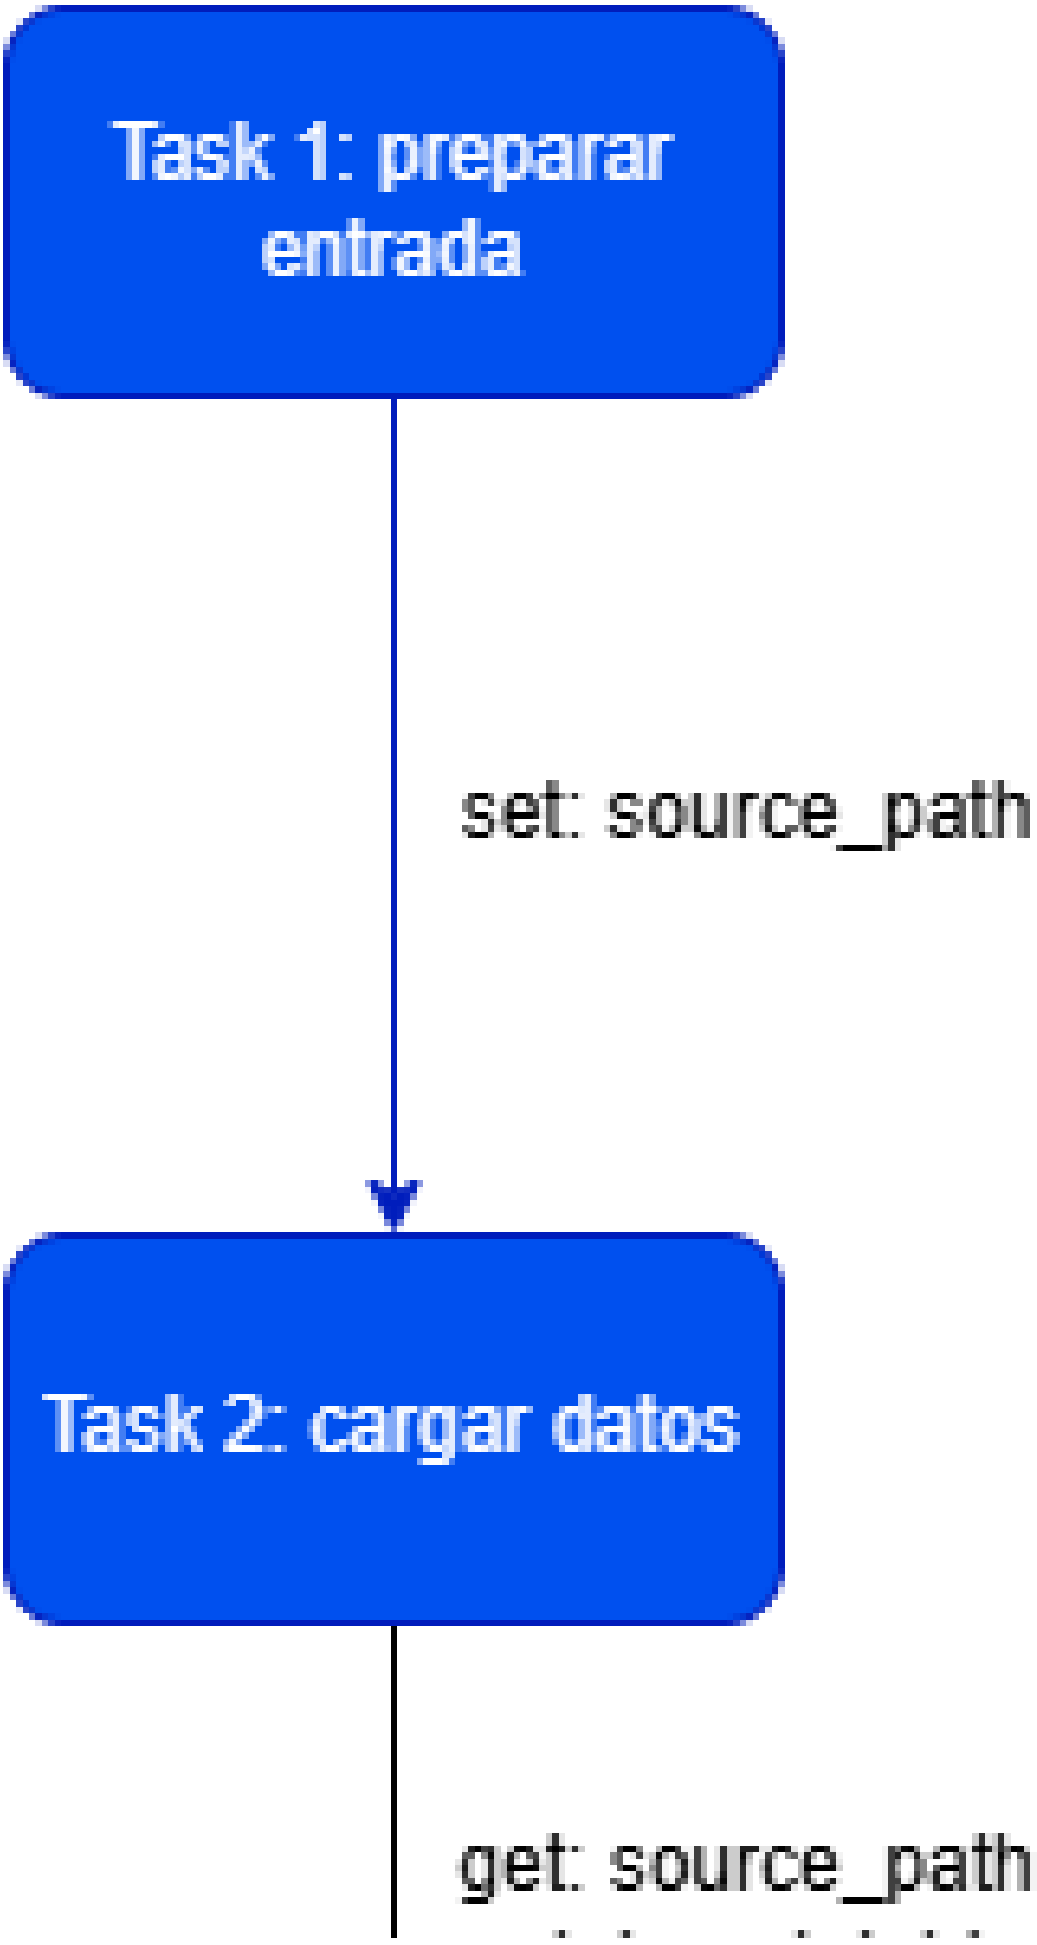
Task 1: preparar entrada
set: source_path
Task 2: cargar datos
get: source_path

Figura 5.5. Comunicación entre tarefas nun workflow de Databricks.
Fonte: elaboración propia.

5.10 Xestión de erros, reintentos e alertas

Nun pipeline operativo non só importa que o proceso se execute, senón tamén saber que ocorre cando algo falla.

Databricks Workflows permite configurar distintos mecanismos de control:

- **retries**, para reintentar tarefas fallidas
- **notifications**, para recibir avisos por erro ou por outros eventos
- **duration thresholds**, para detectar execucións máis longas do esperado
- **repair** ou relanzamento parcial, en determinados escenarios

Isto resulta útil porque nun workflow poden aparecer problemas como:

- erros no código
- fallos ao acceder a datos
- ficheiros ausentes
- execucións máis lentas do previsto

Interesa especialmente comprender que un pipeline real debe ser:

- automatizable
- observable
- recuperable ante fallos

Por iso, ademais de definir tarefas e dependencias, convén pensar tamén en:

- que tarefas deben poder reintentarse
- que eventos deberían xerar unha notificación
- como identificar rapidamente en que paso fallou o proceso

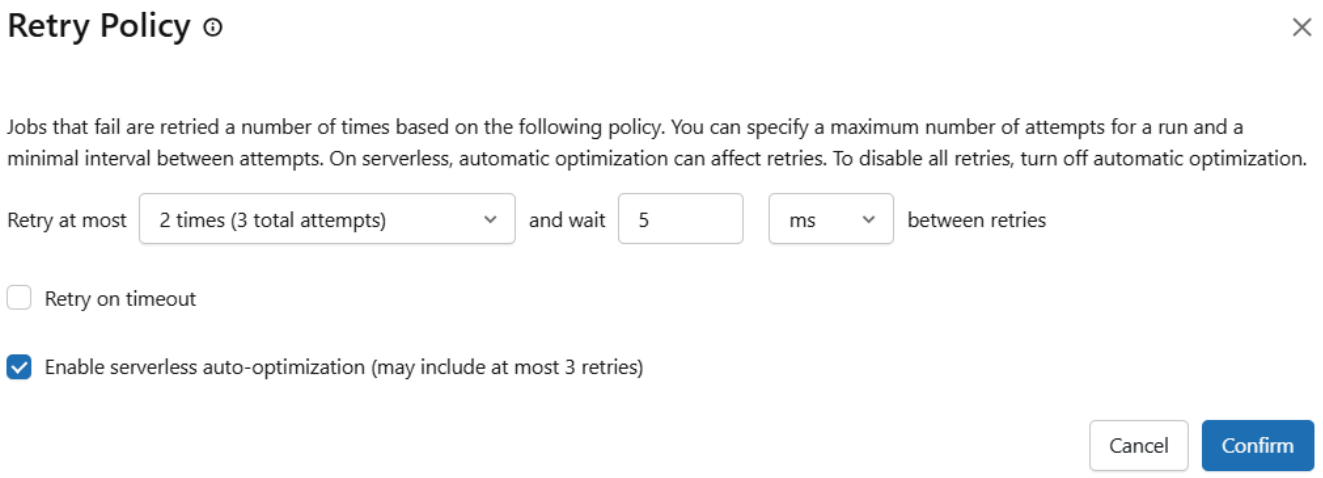

Figura 5.6. Configuración da política de reintentos nunha task dun workflow de Databricks.
Fonte: elaboración propia.

5.11 Relación con outras ferramentas de orquestración

Nunha arquitectura modular, a orquestración adoita realizarse con ferramentas específicas, como **Airflow**.

En Databricks, unha parte desta funcionalidade intégrase dentro da propia plataforma mediante Workflows.

Isto aporta vantaxes como:

- menor necesidade de integrar ferramentas externas
- execución máis próxima aos notebooks e aos datos
- configuración máis simple en contornos pequenos

Con todo, en contornos empresariais máis complexos pode seguir sendo habitual empregar ferramentas externas de orquestración.

5.12 Limitacións e consideracións prácticas

Non todas as funcionalidades de Workflows están sempre dispoñibles do mesmo modo en todos os plans ou contornos.

En determinados contornos e funcionalidades avanzadas pode ser necesario un workspace con **plan premium**.

Por tanto, convén ter presente que:

- algunhas opcións avanzadas poden non estar dispoñibles
- a interface pode variar lixeiramente

- determinados disparadores ou opcións de configuración poden depender do tipo de workspace

En calquera caso, os conceptos fundamentais seguen sendo os mesmos:

- definir tarefas
- establecer dependencias
- executar procesos
- programar runs
- supervisar resultados

5.13 Resumo

Databricks Workflows permite converter tarefas illadas en pipelines automatizados.

As ideas clave son:

- un workflow está formado por tarefas
- as tarefas poden depender unhas doutras
- a execución represéntase como un DAG
- os jobs poden programarse ou lanzarse manualmente
- os runs poden monitorizarse desde a interface
- os parámetros permiten reutilizar a mesma lóxica en distintos contextos

Este compoñente é a base da orquestración dentro de Databricks e completa o papel da plataforma como contorno integrado para o desenvolvemento de pipelines de datos.

5.14 Lakeflow Declarative Pipelines

Ademais de Workflows, Databricks ofrece unha forma declarativa de construír pipelines de datos. Tradicionalmente esta funcionalidade coñeceuse como **Delta Live Tables (DLT)**, pero na documentación máis recente aparece como **Lakeflow Declarative Pipelines (LDP)** ou, nalgúns contextos, **Lakeflow Spark Declarative Pipelines**.

Mentres que en Workflows o habitual é orquestrar tarefas como notebooks ou scripts, en Lakeflow Declarative Pipelines o foco está en declarar:

- as táboas de entrada
- as transformacións entre capas
- as dependencias entre conxuntos de datos
- as regras de calidade

Noutras palabras:

- **Workflows** orquestra tarefas
- **Lakeflow Declarative Pipelines** define o propio pipeline de datos

Neste capítulo seguirase mencionando tamén **Delta Live Tables** cando sexa útil, porque é un nome aínda moi estendido en materiais anteriores, pero convén saber que a denominación actual máis habitual na documentación oficial é **Lakeflow Declarative Pipelines (LDP)**.

Este enfoque encaixa especialmente ben en arquitecturas tipo:

- **bronze**: datos en bruto
- **silver**: datos limpos e transformados
- **gold**: datos preparados para análise

Figura 5.7. Esquema conceptual dun pipeline `bronze / silver / gold` en Databricks.
Fonte: elaboración propia.

5.14.1 Abstraccións principais

Lakeflow Declarative Pipelines traballa principalmente con dous tipos de obxectos persistentes:

- **streaming tables**, pensadas para procesar datos incrementais a medida que van chegando
- **materialized views**, pensadas para manter o resultado actual dunha transformación ou agregación

En termos conceptuais:

- unha *streaming table* utilízase habitualmente nas capas máis próximas á inxestión
- unha táboa materializada resulta natural en capas máis agregadas ou orientadas ao consumo final

Isto explica ben por que Lakeflow Declarative Pipelines encaixa en pipelines de varias capas.

5.14.2 Procesamento declarativo

En Lakeflow Declarative Pipelines, o usuario non se centra tanto en escribir toda a lóxica de execución do pipeline, senón en declarar as transformacións.

Por exemplo, pódense definir:

- táboas de entrada mediante cargas incrementais
- táboas intermedias con limpeza e validación
- táboas finais con agregacións e enriquecementos

O sistema encárgase de aspectos como:

- inferencia de dependencias
- planificación da execución
- actualización das táboas
- seguimento do pipeline

5.14.3 Calidade de datos

Un dos puntos máis importantes deste enfoque é que Lakeflow Declarative Pipelines permite engadir **expectations**, é dicir, regras de calidade sobre os datos.

Estas expectativas permiten comprobar condicións como:

- que unha columna non sexa nula
- que unha clave sexa válida
- que non existan duplicados
- que unha referencia a outra táboa sexa correcta

Segundo a acción configurada, un rexistro que incumpre unha regra pode:

- xerar unha advertencia
- ser descartado
- facer fallar a actualización do pipeline

Este é un dos elementos que diferencian Lakeflow Declarative Pipelines dun conxunto de notebooks encadeados manualmente.

5.14.4 Relación con Workflows

Lakeflow Declarative Pipelines e Workflows non son excluíntes.

De feito, poden complementarse:

- **Lakeflow Declarative Pipelines** define a lóxica do pipeline de datos
- **Workflows** permite lanzar, programar e supervisar execucións dentro dun proceso máis amplo

Nun fluxo máis amplo, unha task dun workflow pode chegar a executar un pipeline do que tradicionalmente se coñecía como Delta Live Tables.

5.14.5 Consideración práctica

Lakeflow Declarative Pipelines é unha ferramenta máis avanzada ca un pipeline manual baseado só en notebooks.

Por iso, interesa principalmente entendela como:

- unha evolución natural dos pipelines manuais
- unha ferramenta especialmente útil para arquitecturas `bronze / silver / gold`
- unha solución que integra transformación, calidade e observabilidade

Interesa sobre todo comprendela a nivel conceptual. Non é necesario dominar toda a configuración de Lakeflow Declarative Pipelines para entender o seu papel dentro do ecosistema de Databricks.

Non se desenvolverá aquí en profundidade toda a súa configuración, pero é importante coñecer a idea xeral porque ocupa un papel central nos pipelines modernos en Databricks.

5.14.6 Exemplo sinxelo con `persoas.csv`

Un modo práctico de entender este enfoque consiste en construír un pipeline declarativo pequeno a partir do ficheiro `persoas.csv`.

Neste caso pódense definir tres saídas encadeadas:

- `persoas_bronze`, como lectura inicial do CSV
- `persoas_silver`, como versión limpa e validada
- `persoas_por_cidade`, como agregación final

Na interface de Databricks, o fluxo habitual consiste en:

1. crear un pipeline novo
2. seleccionar un catálogo e un esquema por defecto para o pipeline
3. engadir un ficheiro Python dentro de `transformations`
4. definir as transformacións con `@dp.materialized_view`
5. executar o pipeline co botón **Run**
6. revisar as dependencias co botón **Pipeline graph** do panel dereito

Mesmo así, nos exemplos resulta útil empregar o nome completo das táboas cando se le unha saída anterior, porque isto deixa máis explícito sobre que catálogo e esquema se está a traballar.

O exemplo podería escribirse así:

```python
from pyspark import pipelines as dp
from pyspark.sql import functions as F


CSV_PATH = "/Volumes/workspace/default/demo_ldp/persoas.csv"


@dp.materialized_view
def persoas_bronze():
    return (
        spark.read
        .option("header", "true")
        .option("inferSchema", "true")
        .csv(CSV_PATH)
    )


@dp.materialized_view
@dp.expect_or_drop("idade_valida", "idade IS NOT NULL AND idade >= 0")
@dp.expect_or_drop("nome_non_baleiro", "nome IS NOT NULL AND trim(nome) <> ''")
def persoas_silver():
    return (
        spark.read.table("workspace.demo_ldp.persoas_bronze")
        .withColumn("nome", F.initcap(F.trim(F.col("nome"))))
        .withColumn("cidade", F.initcap(F.trim(F.col("cidade"))))
        .withColumn("idade", F.col("idade").cast("int"))
    )
```

```python
@dp.materialized_view
def persoas_por_cidade():
    return (
        spark.read.table("workspace.demo_ldp.persoas_silver")
        .groupBy("cidade")
        .agg(
            F.count("*").alias("total_persoas"),
            F.avg("idade").alias("idade_media")
        )
        .orderBy(F.col("total_persoas").desc(), F.col("cidade"))
    )
```

Neste exemplo:

- `persoas_bronze` le o ficheiro de entrada
- `persoas_silver` limpa e valida os rexistros
- `persoas_por_cidade` crea unha saída agregada lista para consulta

As regras `expect_or_drop` mostran tamén unha das vantaxes máis características deste enfoque: as comprobacións de calidade intégranse na propia definición do pipeline, sen necesidade de engadir unha fase separada de validación manual.

Despois de executar o pipeline, a interface pode mostrar o grafo de dependencias entre as tres saídas mediante o botón **Pipeline graph**.

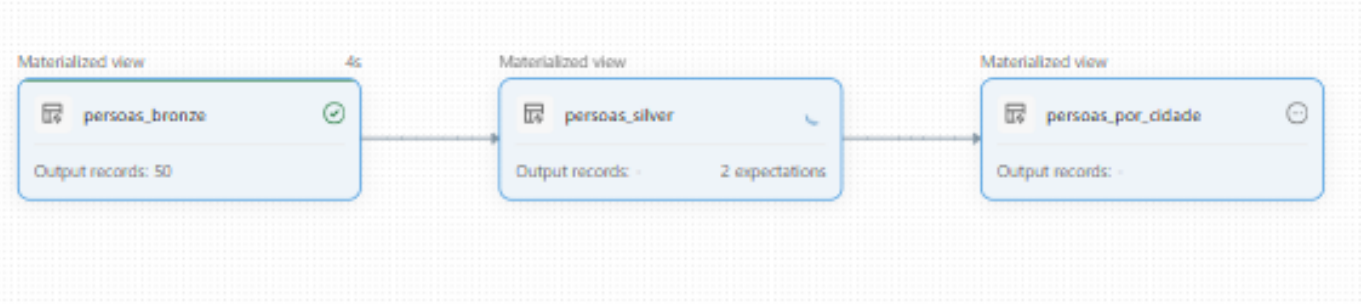

Figura 5.8. Grafo de dependencias dun pipeline declarativo construído a partir de `persoas.csv`.
Fonte: elaboración propia.

Este exemplo permite ver con claridade a diferenza co laboratorio anterior baseado en Workflows: aquí non se está a definir a orde de execución de notebooks independentes, senón a lóxica dun pipeline de datos no que as dependencias entre resultados se deducen a partir das transformacións declaradas.

O mesmo enfoque tamén podería expresarse en SQL, o que resulta especialmente cómodo en exemplos pequenos ou cando se quere poñer o foco nas transformacións sen entrar en detalles de PySpark. Unha versión equivalente podería ser esta:

```sql
CREATE OR REFRESH MATERIALIZED VIEW persoas_bronze
AS
SELECT *
FROM read_files(
```

```
  '/Volumes/workspace/default/demo_ldp/persoas.csv',
  format => 'csv',
  header => true
);

CREATE OR REFRESH MATERIALIZED VIEW persoas_silver
(
  CONSTRAINT idade_valida EXPECT (idade IS NOT NULL AND idade >= 0) ON VIOLATION
DROP ROW,
  CONSTRAINT nome_non_baleiro EXPECT (nome IS NOT NULL AND trim(nome) <> '') ON
VIOLATION DROP ROW
)
AS
SELECT
  initcap(trim(nome)) AS nome,
  cast(idade AS INT) AS idade,
  initcap(trim(cidade)) AS cidade
FROM workspace.demo_ldp.persoas_bronze;

CREATE OR REFRESH MATERIALIZED VIEW persoas_por_cidade
AS
SELECT
  cidade,
  count(*) AS total_persoas,
  avg(idade) AS idade_media
FROM workspace.demo_ldp.persoas_silver
GROUP BY cidade
ORDER BY total_persoas DESC, cidade;
```

En definitiva, tanto a versión en Python como a versión en SQL son dúas formas equivalentes de expresar o mesmo pipeline declarativo.

5.15 Laboratorio guiado: pipeline bronze, silver e gold

Esta práctica final propón un pequeno pipeline sobre un conxunto de datos de vendas, organizado en varias fases e pensado para executarse mediante notebooks parametrizados.

O obxectivo non é construír un sistema de produción completo, senón ver como se poden encadear transformacións reais en Databricks usando o modelo `bronze / silver / gold`.

O laboratorio baséase nos seguintes notebooks do cartafol `Databricks/notebooks`:

- csv_to_bronze.ipynb
- bronze_to_silver.ipynb
- silver_to_gold_country.ipynb
- silver_to_gold_month.ipynb

Este enfoque permite traballar cun laboratorio máis próximo a un caso real e, ao mesmo tempo, manter o capítulo máis limpo e lexible.

5.15.1 Obxectivo

Ao finalizar esta práctica, deberíase ser capaz de:

- cargar un ficheiro CSV nunha táboa da capa `bronze`
- transformar unha táboa da capa `bronze` nunha táboa máis limpa na capa `silver`
- xerar dúas saídas analíticas distintas na capa `gold`
- reutilizar notebooks parametrizados nun workflow
- comprender como unha mesma capa `silver` pode alimentar distintas saídas finais

---

5.15.2 Estrutura do laboratorio

O fluxo xeral proposto é este:

1. ler un ficheiro CSV desde un volume
2. cargar ese ficheiro nunha táboa `bronze`
3. executar un notebook `bronze_to_silver`
4. xerar unha táboa `gold` agregada por país
5. xerar unha táboa `gold` agregada por mes

En termos de saída, o pipeline produce:

- `workspace.bronze.invoices_bronze`
- `workspace.silver.invoices_silver`
- `workspace.gold.sales_by_country_gold`
- `workspace.gold.sales_by_month_gold`

5.15.3 Notebook 1. CSV a bronze

O primeiro notebook do laboratorio é csv_to_bronze.ipynb.

Este notebook encárgase de:

- recibir a ruta dun ficheiro CSV nun volume
- recibir tamén o catálogo, o esquema e o volume de orixe
- definir o esquema de lectura
- crear o esquema de destino da capa `bronze`
- ler o ficheiro coa configuración axeitada
- converter `InvoiceDate` a tipo timestamp
- engadir metadatos como `ingestion_timestamp`, `source_file` e `source_path`
- gardar o resultado como táboa Delta na capa `bronze`

Os parámetros principais son:

- `source_catalog`
- `source_schema`
- `source_volume`
- `source_file`
- `target_catalog`

- `target_schema`
- `target_table`

Por exemplo, a saída natural deste notebook sería `workspace.bronze.invoices_bronze`.

Este paso representa a entrada do pipeline e serve como base para o resto das transformacións.

5.15.4 Notebook 2. Bronze a silver

O segundo notebook do laboratorio é bronze_to_silver.ipynb.

Este notebook:

- recibe como entrada a táboa `bronze`
- limpa rexistros con valores nulos en campos clave
- elimina cantidades e prezos incorrectos
- normaliza algúns campos de texto
- calcula a columna derivada `total_price`
- escribe o resultado na capa `silver`

Os parámetros principais son:

- `source_table`
- `target_catalog`
- `target_schema`
- `target_table`

Este notebook está pensado para ser reutilizable, tanto manualmente como dentro dun workflow.

5.15.5 Notebook 3. Silver a gold por país

O terceiro notebook é silver_to_gold_country.ipynb.

Neste caso, a táboa `silver` utilízase para crear unha saída agregada por país.

O notebook calcula, entre outros elementos:

- número de liñas
- número de pedidos
- total de vendas
- ticket medio

O resultado escríbese como táboa `gold`, por defecto `workspace.gold.sales_by_country_gold`.

Esta saída é útil para responder preguntas analíticas sinxelas, como que países concentran máis volume de vendas.

5.15.6 Notebook 4. Silver a gold por mes

O cuarto notebook é silver_to_gold_month.ipynb.

Neste caso, a táboa `silver` agrégase por mes a partir da columna `InvoiceDate`.

O notebook calcula:

- número de pedidos por mes
- número de clientes distintos
- total de vendas mensual

O resultado escríbese como táboa `gold`, por defecto `workspace.gold.sales_by_month_gold`.

Esta variante permite ver que unha mesma capa `silver` pode dar lugar a distintas saídas finais, segundo a necesidade analítica.

5.15.7 Orde de execución

Nunha execución manual, a orde recomendada sería:

1. executar `csv_to_bronze.ipynb`
2. executar `bronze_to_silver.ipynb`
3. executar `silver_to_gold_country.ipynb`
4. executar `silver_to_gold_month.ipynb`

Nun workflow, a dependencia máis natural sería esta:

- unha task inicial `csv_to_bronze`
- unha task `bronze_to_silver` dependente da anterior
- unha task `silver_to_gold_country` dependente de `bronze_to_silver`
- unha task `silver_to_gold_month` dependente de `bronze_to_silver`

É importante remarcar que **non existe dependencia entre os dous notebooks `gold`**. Os dous parten da mesma saída `silver`, pero xeran produtos analíticos distintos e poden executarse en paralelo.

Este enfoque mostra ben que unha mesma saída `silver` pode alimentar varias ramas do pipeline.

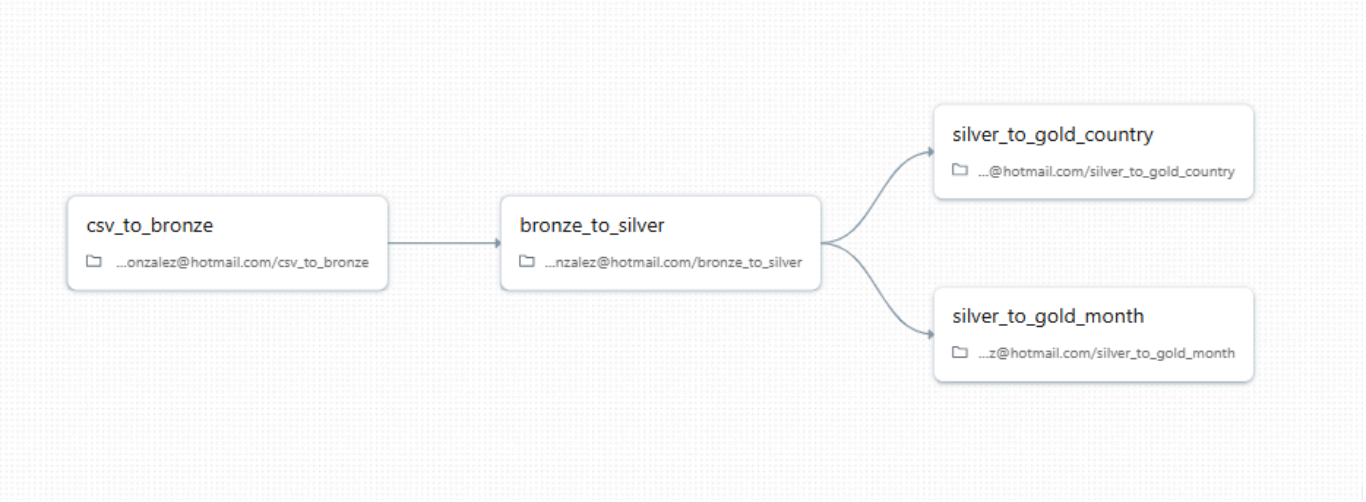

Figura 5.9. Dependencias entre tarefas no workflow do laboratorio `bronze / silver / gold`.
Fonte: elaboración propia.

5.15.8 Interpretación do resultado

Ao finalizar o laboratorio, as capas cumpren funcións distintas:

- **bronze** incorpora o dato de entrada desde o CSV á estrutura tabular do pipeline
- **silver** concentra a limpeza, normalización e enriquecemento básico
- **gold** ofrece táboas xa preparadas para análise

Neste exemplo, a capa `gold` non é única, senón que se desdobra en dúas saídas:

- unha orientada a análise xeográfica
- outra orientada a análise temporal

Neste punto resulta especialmente útil incorporar unha captura dunha das táboas `gold`, preferiblemente a saída por país, xa que adoita ser a máis fácil de interpretar visualmente.

Assistant

To analyze the sales data by country, we will look at the table `workspace.gold.sales_by_country_gold`, which contains information on country names, the number of sales lines, the number of orders, total sales, and the average ticket value. Here is a query that retrieves all the records from this table:

```
SELECT *
FROM `workspace`.`gold`.`sales_by_country_gold` LIMIT 20
```

Run Query | Open in Editor

Sample | Result

	Country	num_linhas	num_pedidos	total_vendas	ticket_medio
1	United Kingdom	354321	16646	7308391.55	20.63
2	Netherlands	2359	94	285446.34	121.0
3	EIRE	7236	260	265545.9	36.7
4	Germany	9040	457	228867.14	25.32
5	France	8341	389	209024.05	25.06
6	Australia	1182	57	138521.31	117.19
7	Spain	2484	90	61577.11	24.79
8	Switzerland	1841	51	56443.95	30.66
9	Belgium	2031	98	41196.34	20.28
10	Sweden	451	36	38378.33	85.1
11	Japan	321	19	37416.37	116.56
12	Norway	1071	36	36165.44	33.77
13	Portugal	1462	57	33439.89	22.87
14	Finland	685	41	22546.08	32.91
15	Singapore	222	7	21279.29	95.85
16	Channel Islands	748	26	20450.44	27.34
17	Denmark	380	18	18955.34	49.88
18	Italy	758	38	17483.24	23.06
19	Cyprus	614	16	13590.38	22.13
20	Austria	398	17	10198.68	25.62

Figura 5.10. Exemplo de saída `gold` agregada por país.
Fonte: elaboración propia.

Este patrón é moi habitual en pipelines reais.

5.15.9 Relación con Workflows e Lakeflow Declarative Pipelines

Este laboratorio está deseñado para funcionar moi ben con **Workflows**, porque cada notebook pode converterse nunha task parametrizada.

Un deseño moi natural sería:

- unha task `csv_to_bronze`
- unha task `bronze_to_silver`
- unha task `silver_to_gold_country`
- unha task `silver_to_gold_month`

Coa task `bronze_to_silver` dependendo de `csv_to_bronze`, e coas dúas tasks `gold` dependendo de `bronze_to_silver`.

De novo, convén deixar claro que `silver_to_gold_country` e `silver_to_gold_month` non dependen unha da outra. As dúas comparten a mesma entrada `silver`, pero producen saídas diferentes.

Desde un punto de vista conceptual, o mesmo laboratorio tamén permite entender por que Lakeflow Declarative Pipelines resulta útil: as dependencias entre capas e saídas finais xa están bastante claras e poden expresarse de forma máis declarativa nun enfoque máis avanzado.